

App-Level TinyML für Akkulaufzeit-Vorhersage auf Android

Multi-Device-Vergleich von sechs Methoden

Keno Schürger

Matrikelnr.: 5023033

Technische Hochschule Würzburg-Schweinfurt (THWS)

Vertiefungsseminar - Sommersemester 2026

Motivation und Forschungsfrage

- Die Akku-Restzeit-Anzeige im System ist oft unzuverlässig (rechnet grob den Schnitt hoch).
- Seit Android 12 gibt es ein eigenes ML-Modell im System, aber nur mit privilegiertem Zugriff. Normale Apps kommen da nicht ran.

"Wie gut kann ein TinyML-Modell die Akkulaufzeit auf Android vorhersagen, im Vergleich zu linearem und exponentiellem Fitting sowie der nativen Google-API, bezogen auf Genauigkeit und Effizienz?"

Gemessen an zwei Achsen: Genauigkeit (C-Index, MAE) und Effizienz (Modellgröße, Latenz).

Verwandte Arbeiten

Li et al. (2018)

Smartphone Battery Prediction at Scale

51 Nutzer, 21 Monate. Führt den Concordance-Index als Metrik ein, weil Nutzer fast nie auf 0% entladen und MAE dann unzuverlässig wird. Der C-Index stammt aus der Medizin.

Albelali & Ahmed (2025)

Hidden Leaks in Time Series Forecasting

Zufälliges Mischen von Sliding-Window-Sequenzen leckt Zukunfts-Information ins Training und schön die Ergebnisse.

Datensammlung: 4 Geräte, 45 Tage

66.001

Messungen

4

Geräte

45 Tage

Zeitraum

180

Sessions

- Eigener Xiaomi plus drei Pixel-Geräte (7, 8, 9 Pro), bei Familienmitgliedern.
- Alle 30 Sekunden ein Messpunkt, im Hintergrund über einen Foreground-Service.

10 Features (nur öffentliche Sensoren)

battery_level, screen_on,
brightness, active_app_category,
wifi_on, mobile_data_on,
charging, cpu_usage (proxy),
temperature, hotspot_on

Sechs Methoden im Vergleich

TinyML Conv1D

Eigenes Modell, 14 KB INT8

Hauptmodell

Random Forest

200 Trees, gleiche Features

Sanity-Check

Mean Predictor

Konstanter Mittelwert

Floor (kein Lernen)

Linear Baseline

Akku / aktuelle Drain-Rate

Analytisch 1

Exponential Fit

Kurvenfit pro Segment

Analytisch 2

Google API

getBatteryDischargePrediction

State of the Art


Ergebnis: 6-Wege-Vergleich

C-Index: bewertet nur ob die Reihenfolge stimmt (0,5 = Münzwurf, 1,0 = perfekt). MAE: durchschnittliche Abweichung in Stunden.

Methode	MAE (h)	C-Index 95%-CI	Acc +/- 2h
Mean Predictor (floor)	6.52	0.500 [0.500, 0.500]	21.5%
TinyML Conv1D	4.60	0.656 [0.647, 0.664]	43.7%
Random Forest	4.06	0.685 [0.673, 0.695]	46.4%
Linear (drain rate)	3.30	0.770 [0.761, 0.780]	57.3%
Exponential fit	3.63	0.767 [0.758, 0.776]	59.0%
Google API	3.37	0.762 [0.751, 0.772]	59.0%

Beide ML-Modelle signifikant über dem Floor ($p < 0,001$), aber unter der Spitzengruppe. **Überraschend: Google ist statistisch nicht besser als die simple Linear-Baseline ($p = 0,11$).**

Per-Device: starker Hardware-Effekt



Beobachtungen

- Dasselbe TinyML: 0.75 (Pixel 7 Pro) bis 0.59 (Xiaomi)
- Analytische Baselines stabiler über Geräte
- Praktisch: Konfidenz sollte gerätespezifisch sein

Effizienz: TinyML funktioniert

14.4 KB

INT8 Modell

3.3 μ s

Inferenz-Latenz

7.6x

kleiner als das Original-Modell

~12.000x

schneller als das Original

Original-Modell = unquantisierte Float32-Version (109 KB, 39 ms).

Take-away

Die Quantisierung funktioniert wie beworben. Effizienz ist die klare Stärke von TinyML. Der Engpass liegt allein bei der Genauigkeit.

Kernbefunde

Genauigkeit **TinyML unterlegen**

Bleibt unter Linear, Exponential und Google ($C \sim 0,77$). Google ist nicht besser als die simple Linear-Baseline.

Effizienz **TinyML überlegen**

14,4 KB, 3,3 Mikrosekunden, läuft offline. Hier hat TinyML klar seinen Wert.

Hardware **stark geräteabhängig**

C-Index 0,75 auf Pixel 7 Pro gegen 0,59 auf Xiaomi (gleiches Modell, anderes Gerät).

Grenzen: Handy nie ganz leer, nur 4 Geräte.

Antwort auf die Forschungsfrage

Wie gut sagt ein App-Level-TinyML-Modell die Akkulaufzeit vorher, verglichen mit etablierten Methoden und der Google-API?

Genauigkeit: erreicht die etablierten Methoden nicht

TinyML lernt Signal über dem Floor, bleibt aber hinter Linear, Exponential und Google ($C \sim 0.77$). Und Google ist nicht besser als die simple Linear-Baseline.

Effizienz: hier ist TinyML klar überlegen

14,4 KB, 3,3 Mikrosekunden Inferenz, läuft komplett offline auf jedem Android-Gerät.

Vielen Dank. Fragen?